

TEKNİK RAPOR:
MAKİNE ÖĞRENMESİ İLE SAHTECİLİK
TESPİTİ

İçindekiler Tablosu

1) Data Preprocessing / Veri Ön İşleme	3
A. Veri Setini İnceleme	3
B. Veri Temizleme	3
C. Feature Engineering (Özellik Mühendisliği)	4
D. Outlier Analizi & Scaling & Covariance.....	5
2) Model Eğitimi ve Performans Ölçümü.....	5
E. Logistic Regression (LR).....	5
F. Random Forest (RF).....	6
G. XGBoost (XGB).....	6
H. Balanced Random Forest (BRF).....	6
İ. Ensemble Learning ve Voting Classifier	6
J. Feature Seçimi	7
K. Performans İyileştirme Çabaları.....	8
3) Model/Performans Değerlendirmesi	9
4) Model Deployment (REST API)	10

1) Data Preprocessing / Veri Ön İşleme

Projenin bu aşamasında, en az değişken ile en fazla bilgiye ulaşmak hedeflenerek veri seti incelenmiş ve temizlenmiştir.

Temizlenen veriden ilk feature'lar seçilmiştir ve model eğitime geçilmiştir. Eğer sonuçlar istendiği şekilde olmazsa ileride feature seçimi değiştirilebilir.

A. Veri Setini İnceleme

849,564 satırlık veri seti kolonlar, değerler ve veri tipleri bakımından incelenmiştir. Sahtecilik tespitinde faydalı olabilecek, kullanılmayacak, nümerik dönüşüm (encoding) yapılacak, ölçeklenecek (scaling) ve null değerli kolonlar hakkında çıkarımlar yapılmıştır.

Genel veri seti kontrol edildikten sonra sahtecilik işlemlerini anlamak için *IsFraudTransaction*'ı 1 olan satırlar filtrelenip incelenmiştir. Önemli olabilecek kolonlar hakkında fikir yürütülmüş ve kolonların değerleri incelenmiştir. Bu çıkarımlar feature seçilirken kullanılmıştır.

İlk incelemeye göre bazı çıkarımlar yapılmıştır:

- Geçersiz cihaz modelleri (KUVEYT TURK KATILIM BANKASI ÇEKİLİŞ ONAY, KUVEYT TURK KATILIM BANKASI CAGRI MERKEZI) bulunmaktadır.
- IP_Subnet'i aynı olan (91.151.xxx, 178.240.xxx) işlemlerde sahtecilik görülür.
- Unique IP count'u düşük işlemler fraud olmaya yakın olabilir.
- CustomerTenure önemli olabilir yüksekse fraud olmayabilir.

Verideki bazı tutarsızlıklar ve pattern'lar tespit edilse de birçoğu sentetik veriden kaynaklı görülüp değerlendirmeye alınmamıştır:

- Alıcı adındaki unvanla alıcı meslekleri uyuşmamaktadır. Alıcı adı ve cinsiyet uyuşmamaktadır. Eğitim bilgisi ve meslek (lise mezunu dış hekimi vb.) uyuşmamaktadır.
- Bu tarz tutarsızlıklar veriyi gruplamadaki seçimleri etkilemiştir. Örneğin normalde meslekler gelir düzeyi ile gruplanabilirken bu vaka için sıklığa göre gruplama tercih edilmiştir.

B. Veri Temizleme

Unique veriler ve NLP/LLM kullanılmadan anlamlandıramayacağımız stringler (*BusinessKey*, *ReceiverName*, *SenderName*, *CustomerName*) temizlenmiştir. Tek değer içeren *TransactionChannel* kolonu da temizlenmiştir.

Null veriler içeren kolonlar için şu **null-handling** stratejileri uygulanmıştır:

- *DayType*: Resmi tatil bilgisi nümerikleştirilerek null handling yapıldı.

- *CustomerMaritalStatus*: Null değerler gözardı edilebilecek kadar az (188/849564) olduğu için bu satırlar temizlendi.
- *CustomerEducation*: Ordinal encoding ile eğitim basamaklarına göre nümerikleştirildikten sonra null kayıtlara ortalama eğitim değeri atandı.

Encoding ile kategorik veriler nümerikleştirilmiştir.

- *CustomerSegment*, *TransactionType*, *DeviceOSName*, *DayType*, *IsFractionalAmount*, *CustomerEducation* kolonlarının değerleri bilindiğinden ve sıralı olduğundan kolonlar **ordinal encoding** ile nümerikleştirilmiştir.
- *CustomerMaritalStatus*, *CustomerGender*, *CustomerProfession* (gruplandıktan sonra), *CustomerAge* (binning sonrası) **one-hot encoding** ile nümerikleştirilmiştir.
 - *CustomerProfession* yüksek kardinaliteye sahip olduğu için **target encoding** kullanımı da değerlendirilmiştir. Az sayıda işlem içeren mesleklerde overfitting'e sebep olabileceğinden tercih edilmemiştir.
 - *CustomerAge* için lineer olmayan davranışları yakalayabildiği için one-hot encoding tercih edilmiştir.

C. Feature Engineering (Özellik Mühendisliği)

Model başarısını artırmak için şu yeni özellikler türetilmiştir:

- *CustomerProfession* Gruplama: 100+ başlık en sık geçen 10 (*N*) grup ve 'Other' olarak sadeleştirilmiştir. Sonuçlara göre *N* değeri değiştirilebilir. Overfitting'i önlemek amacıyla yüksek *N* değerleri tercih edilmemiştir.
- *IsFlaggedDeviceModel*: Cihaz adında geçen geçersiz/şüpheli stringler incelenmiştir. Business mantıklı 'Kuveyt Turk', 'Onay' gibi kelimeler geçen veya geçerli bir cihaz modelinden (35 karakterden) uzun olan şüpheli modeller flag'lenmiştir.
- *TransactionDate*: Pattern tespiti amacıyla tarih bilgisi saat, haftanın günü ve ay olarak bölünmüştür.
- *RecentSimilarTransactionsCount*: Son *t* saat içindeki benzer tutarlı işlemler (velocity) optimal değerlerle hesaplanmıştır. *TP/FP* analizi yapıldığında başarılı sonuçlar vermediği görülmüştür.
 - Farklı zaman aralıkları (1h, 2h, 3h, 6h) ile denenmiştir.
 - *AccountNumber* ve/ya da *DeviceId*'ye göre gruplamalar denenmiştir.
 - Farklı *TransactionAmount* yuvarlamalarıyla (100, 1000) denenmiştir.
- *CustomerAge* verisi business mantığına göre oluşturulan bin'lerle (18-25, 25-40, 40-55, 55+) gruplanmıştır (**binning**). Denenen bin'lerin yoğunluğuna göre optimum bin seçimleri yapılmıştır.
 - *IP* ve *Subnet* Analizi: *IP_Subnet*'i aynı olan ve *UniqueIPCount*'u düşük olan işlemlerin şüpheli olduğu görülmüştür. Bu varsayımlar *IP_Subnet* verisi için sıklığa göre gruplanarak, *UniqueIPCount* verisi için de **outlier analizi** ile çıkarıma dönüştürülmüştür.

- Fraud oranı %15'ten yüksek olan ve en az 5 işlem almış subnet'ler *IsHighRiskIPSubnet* olarak flag'lenmiştir.
- *UniqueIPCount* için outlier analizi sonucunda elde edilen Q1 değerine göre risk flag'i oluşturulmuştur.
 - *FP* değerlerin fazla bulunması nedeniyle risk treshold'u için daha iyi bir değer araştırılmıştır. Ancak precision'ı artırırken flag'lenen veri hacmi çok azaldığı için feature optimizasyonu gerekmedikçe Q1 ile devam edilmesine karar verilmiştir.
- *IsSharedDevice*: Aynı cihazdan birden fazla hesaba giriş yapılması durumu tespit edilmiştir.

D. Outlier Analizi & Scaling & Covariance

Outlier analizi için **Interquartile Range (IQR)** metodu kullanılmıştır. *TransactionAmount* ve *CustomerTenure* kolonlarında outlier'lardaki fraud oranının global oranın 2 katı olduğu görülmüştür. Bu durum yüksek miktarlı işlemlerin ve uzun süreli müşterilerin fraud işlemi belirtmesinin daha muhtemel olduğunu gösterir. Bu veriler silinmemiş, bunun yerine outlier'lardan daha az etkilenen medyan tabanlı **RobustScaler** kullanılarak ölçeklendirilmiştir (**scaling**).

Üretilen feature'ların **covariance**'ları kontrol edilmiştir. Yüksek korelasyonlu feature'ların ($r > 0.9$) model başarısını etkilememesi için lineer ilişkili feature'lar temizlenmelidir. 90% üzerinde korelasyonu olan kolon çifti bulunmamıştır.

2) Model Eğitimi ve Performans Ölçümü

Veri seti imbalanced olduğu için Stratified Split kullanılmıştır. %80 train %20 test verisine bölünmüştür. *IsFraudTransaction* tahmini hedefiyle işlenen tüm feature'lar başlangıçta modellere verilmiştir.

E. Logistic Regression (LR)

Imbalanced veri setine göre konfigüre edilip (*class_weight='balanced'*) tüm feature'lar verilerek denenmiştir.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.94	0.97	0.9592
1	0.08	0.85	0.15	

Tablo 1: Logistic Regression performans ölçümü

Recall değeri istendiği gibi yüksektir ancak Precision değeri çok düşüktür. FP fazla olduğundan yanlış alarm üretir.

F. Random Forest (RF)

100 karar ağacıyla ($n_estimators=100$) ve balanced ağırlıkla ($class_weight='balanced'$) denenmiştir.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	1.00	1.00	0.9171
1	0.91	0.47	0.62	

Tablo 2: Random Forest performans ölçümü

Precision değeri istendiği gibi yüksektir ancak Recall değeri fraud tespiti için çok düşüktür. Çok az yanlış alarm üretir ama fraud işlemlerin yarısından fazlasını kaçıır.

G. XGBoost (XGB)

Azınlık fraud verisine göre scaled ağırlıkla denenmiştir.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.97	0.98	0.9529
1	0.13	0.80	0.23	

Tablo 3: XGBoost performans ölçümü

Recall değeri istendiği gibi yüksektir ancak Precision değeri çok düşüktür. FP fazla olduğundan yanlış alarm üretir. LR'dan iyi sonuç verir, fraud tespiti için Recall öncelendiğinden RF yerine daha tercih edilebilir.

H. Balanced Random Forest (BRF)

Imbalanced veri setleri için özel olarak geliştirildiğinden denenmiştir. Fraud durumu için RF'tan daha doğru sonuçlar verse de RF'ın Voting Classifier'ı dengelemesi nedeniyle bu yöntemle devam edilmemiştir.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.93	0.96	0.9588
1	0.07	0.87	0.13	

Tablo 4: Balanced Random Forest performans ölçümü

İ. Ensemble Learning ve Voting Classifier

LR ve XGB sonuçları yüksek recall düşük precision, RF sonuçları da tam tersini gösterir. Bu sonuçları birleştiren bir yöntem denenmiştir. Daha önce eğitilmiş performans ölçülen modeller (LR + RF + XGB) Soft Voting Ensemble ile bir araya getirilmiştir. RF yerine BFR ile de

denenmiştir ama BFR diğer iki modele yakın sonuçlar verdiği için ortalaması alınınca başarı düşmüştür.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.99	0.99	0.9642
1	0.31	0.75	0.44	

Tablo 5: Voting Classifier (LR + RF + XGB) performans ölçümü

TN: 167060	FP: 1748
FN: 272	TP: 796

Tablo 6: Voting Classifier Confusion Matrix

Precision ve F1 Score oldukça iyileşir. Recall'da da ciddi düşüş görülmemiştir. En yüksek F-1 Score ve ROC AUC Score'a sahip modeldir. Bu yöntemin kullanılmasına karar verilmiştir.

Sonuçların güvenilir (robust) olması için seçilen model üzerinde StratifiedKFold uygulanmıştır.

Ortalama Recall	0.7394 (+/- 0.0154)
Ortalama Precision	0.3030 (+/- 0.0079)
Ortalama ROC AUC	0.9566 (+/- 0.0041)

Tablo 7: Voting Classifier Cross Validation sonuçları

J. Feature Seçimi

Tüm feature'lar kullanılarak elde edilen ilk performansı iyileştirmek için **Feature Importance**, **L1 Regularization (Lasso)**, **Recursive Feature Elimination** ile farklı feature seçimleri denenmiştir.

Tree tabanlı (Random Forest, XGBoost) modellerde **Feature Importance** bakılarak sonucu en çok etkileyen/etkilemeyen feature'lar bulunmuştur. Deneysel olarak en önemsiz N feature eksiltilerek performans ölçülmüştür.

- Feature'lar kendi başlarına önemli olmasalar da ilişkisel olarak kullanılabildiklerinden sonuçlarda büyük bir değişiklik olmamış, yer yer düşüşler gerçekleşmiştir. Bu yaklaşımdan vazgeçilmiştir.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.97	0.98	0.9480
1	0.13	0.79	0.23	

Tablo 8: En önemsiz 10 feature (<0.0067) eksiltilmiş XGBoost performansı

LR için **L1 Regularization** ile ceza uygulayarak önemsiz özellik katsayısı düşürülmüş, performans değişimi incelenmiştir.

- Farklı ceza katsayıları (c) ile denenmiştir. $c = 0.01$ için 6 feature elimine edilmiştir ve sonuç çok az iyileşmiştir. Ancak LR için başlangıç Precision sonucu çok düşük olduğu için bu iyileştirme yeterli olmamıştır.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.99	0.99	0.9642
1	0.31	0.75	0.44	

Tablo 9: $c = 0.01$ için 6 feature eksiltiyle LR performansı

LR için **Recursive Feature Elimination (RFE)** denenmiştir ve optimal feature sayısı 33 olarak bulunmuştur. *Transaction_day_of_week* ve *Transaction_month* feature'ları elenmiştir. Önerilen feature seçimi uygulandığında sonuçlarda iyileşme görülmemiştir.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.94	0.97	0.9591
1	0.08	0.85	0.15	

Tablo 10: RFE sonrası LR performansı

Denenen feature seçim yöntemleri beklenen iyileştirmeyi sağlamamıştır. Bu nedenle tüm feature'lar kullanılarak devam edilmiştir.

K. Performans İyileştirme Çabaları

Literatürde imbalanced dataset'ler için önerilen iyileştirme yöntemleri denenmiştir:

- StratifiedKFold:** KFold Cross-Validation'da veri k alt kümeye bölünür. Bu kümeler arasında gezerek variance düşürülür. StratifiedKFold ile bölünmeler stratified (azınlık veri için dengeli) bölünür.
 - StratifiedKFold direkt olarak sonuçlarda iyileştirme sağlamasa da şimdiye kadar elde edilen sonuçların daha güvenilir (robust) olduğunu doğrular. Variance'ı düşürerek stabilite sağlar. Feature seçimini de daha stabil hale getirir. Bir kümede (fold) iyi çalışmayan bir feature başka birinde iyi sonuçlar verebilir.
- Balanced Bagging Classifier:** Farklı alt kümelerde çoklu classifier'ları train edip sonuçları ortalar. Çoğunluk sınıfı under-sampling ile azınlık sınıfa dengeler, bias'ı düşürür, azınlık sınıfın performansını iyileştirir.
 - XGBoost ile denendiğinde Balanced Bagging Classifier çoğunluk sınıfından under-sampling yaptığı için Recall çok hassaslaşmıştır çünkü fraud pattern'larına daha duyarlıdır. Ancak bu FP'i çok arttırdığından Precision çok düşmüştür.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.62	0.77	0.9544
1	0.02	0.97	0.03	

Tablo 11: XGB ile Balanced Bagging Classifier performansı

- Bu nedenle daha iyi sonuçlar alma beklentisiyle yöntem Precision'ı daha yüksek, Recall'u daha düşük olan Random Forest ile de denenmiştir. Beklendiği gibi RF sonuçları daha dengeli hale gelmiştir. Ancak bu iyileştirme ile bile XGBoost sonuçları daha avantajlıdır bu nedenle kullanımı tercih edilmemiştir.

	Precision	Recall	F1-Score	ROC AUC Score
0	1.00	0.96	0.98	0.9615
1	0.11	0.85	0.19	

Tablo 12: RF ile Balanced Bagging Classifier performansı

3) Model/Performans Değerlendirmesi

Fraud tespiti, gerçek hayatta da imbalanced veri setleri ile yapıldığı için metriklerin anlamlandırılması ve öncelenmesi oldukça önemlidir.

Yapılan model tercihlerinde ve iyileştirmelerde öncelikle **Recall (Duyarlılık)** değerlendirilmiştir. Fraud işlemlerin çoğunluğunun yakalanması bankanın yaşayacağı maddi kayıpların ve legal sorunların önüne geçer. Sonrasında **Precision (Kesinlik)** dikkate alınır. False Positive'lerin yüksek olması (precision'ın düşük olması) fraud olmayan işlemler için yanlış alarm oluşturur. Müşterilerin işlemleri incelemeye alınabileceğinden/bloke edilebileceğinden kullanıcı deneyimi olumsuz etkilenir. Bu iki değer harmonik ortalaması için **F-1 Score**'a bakılır. Modelin sınıfları birbirinden ayırma becerisi de **ROC AUC** ile ölçülür.

	Precision	Recall	F1-Score	ROC AUC
LR	0.08	0.85	0.15	0.9592
RF	0.91	0.47	0.62	0.9171
XGB	0.13	0.80	0.23	0.9529
BRF	0.07	0.87	0.13	0.9588
Ensemble	0.31	0.75	0.44	0.9642

Tablo 13: Denenen modellerin performans karşılaştırması

RF, ilk kıyaslama için (LR-RF-XGB) F1-Score bakımından en başarılı modeldir. Precision'ı oldukça yüksek, Recall'u da diğer modellerin Precision oranlarına göre daha iyidir. Ancak fraud tespitinde işlem kaçırmının maliyeti çok yüksek olabileceğinden Recall değerinin yüksek olması öncelenir.

LR ve **XGB** için Recall değerleri istenen şekilde yüksektir. Ancak Precision değerleri oldukça düşüktür. Bu FP ve yanlış alarmları arttıracığından bunların iyileştirilmesi için çeşitli yöntemler denenmiştir.

Sonradan imbalanced veri setleri için geliştirilmiş BRF da denenmiştir ancak RF'ın Voting Classifier'ı dengeleyerek daha yüksek başarı sağlamasından dolayı kullanılmamıştır.

3 modelin farklı Precision ve Recall sonuçları vermesi nedeniyle bu yöntemleri birleştirecek bir yöntem araştırılmış, bu modellere Ensemble Learning uygulanmıştır.

Daha önce eğitilip performansı ölçülen modeller (LR + RF + XGB) Soft Voting ensemble ile bir araya getirilmiştir. *Tablo 13*'te görüldüğü üzere Precision ve F1 Score oldukça iyileşir, Recall'da da ciddi düşüş görülmez. Bu yöntemin kullanılmasına karar verilmiştir.

Balanced Bagging Classifier uygulanarak iyileştirilmiş RF ile de Ensemble Learning denenmiştir ancak sonuçlar kıyasla daha başarısızdır. Bu nedenle LR + RF + XGB ile kullanılmasına karar verilmiştir. StratifiedKFold ile modelin robust çalıştığı kanıtlanmıştır.

Baz Model	Uygulanan Yöntem	Δ Precision	Δ Recall	Δ F1-Score	Δ ROC AUC
LR	Lasso (C=0.01)	0.23	-0.10	0.29	0.0050
LR	RFE (33 Feature)	0.00	0.00	0.00	-0.0001
XGB	Feature Selection (-10)	0.00	-0.01	0.00	-0.0049
XGB	Balanced Bagging	-0.11	0.17	-0.20	0.0015
RF	Balanced Bagging	-0.80	0.38	-0.43	0.0444

Tablo 14: Feature seçimi ve iyileştirme denemelerinin performansa etkisi

Sonuçların iyileştirilmesi adına LR için L1 Regularization (Lasso), Recursive Feature Elimination; RF için Balanced Bagging Classifier; XGB için Feature Importance, StratifiedKFold, Balanced Bagging Classifier denenmiştir. RF için Balanced Bagging Classifier başarılı olmuş ve Recall seviyesi iyileştirilmiştir ancak XGB'nin altında kalmıştır.

Gelecekte bankanın stratejik kararlarına göre metriklerin önemi değişebilir ve seçimler güncellenebilir. Farklı feature treshold'ları denenerek sonuçlar iyileştirilebilir. Elendiğinde sonucu etkilemediği düşünülen feature'lar veri hazırlığında hiç üretilmeyebilir.

4) Model Deployment (REST API)

Eğitilen Ensemble model, Flask kullanılarak bir REST API haline getirilmiştir. API, gelen ham veriyi notebook'taki tüm işleme adımlarından (preprocessing & alignment) geçirerek gerçek zamanlı tahmin üretmektedir. Test seti ile test senaryosu oluşturup API'nin çalışması test edilmiştir.